МОНГОЛ УЛСЫН ШИНЖЛЭХ УХААН ТЕХНОЛОГИЙН ИХ СУРГУУЛЬ
МЭДЭЭЛЭЛ, ХОЛБООНЫ ТЕХНОЛОГИЙН СУРГУУЛЬ

KOICA
Korea International Cooperation Agency

Машин сургалт: Удирдлагатай сургалт

Лабораторийн удирдамж №

Компьютерын ухааны салбар

This e-learning content was developed by the support of KOICA



Дэд профессор, док (PhD), Д.Золзаяа /email: zolzaya@must.edu.mn/
Компьютерын ухааны салбар

Лабораторийн дасгал

- Удирдлагатай сургалтын үндсэн ойлголтыг ойлгож, бодит өгөгдөл дээр хэрэгжүүлэх.
- Линейр регресс, логистик регресс, модон шийдвэр (decision tree) зэрэг удирдлагатай сургалтын алгоритмуудыг ашиглаж, таамаглал гаргах чадварыг эзэмших.
- Моделиудын гүйцэтгэлийг хэмжих болон харьцуулах.



Лабораторийн дасгал

Boston Housing Dataset-ийг ашиглан linear регресс ашиглах

```
from sklearn.datasets import load_boston
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error

# Boston Housing Dataset ачаалах
boston = load_boston()
data = pd.DataFrame(boston.data, columns=boston.feature_names)
data['PRICE'] = boston.target

# Өгөгдлийг сургалт (train) болон шалгалтын (test) хэсэгт хуваах
X = data.drop('PRICE', axis=1)
y = data['PRICE']
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
```



Лабораторийн дасгал

Boston Housing Dataset-ийг ашиглан linear регресс ашиглах

```
# Загвар сургах
model = LinearRegression()
model.fit(X_train, y_train)

# Урьдчилсан таамаглал гаргах
y_pred = model.predict(X_test)

# Үр дүнг үнэлэх
mse = mean_squared_error(y_test, y_pred)
print(f"Mean Squared Error: {mse}")
```

Загварын R^2 утгыг тооцоол.

Өөр параметрүүдийг (features) сонгож, загварын гүйцэтгэлийг сайжруул.



Лабораторийн дасгал

Titanic Dataset-ийг ашиглан модоор ашиглах

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import classification_report

# Titanic Dataset ачаалах
url = 'https://raw.githubusercontent.com/datasciencedojo/datasets/master/titanic.csv'
data = pd.read_csv(url)

# Өгөгдлийг боловсруулах
data = data[['Pclass', 'Sex', 'Age', 'Survived']].dropna()
data['Sex'] = data['Sex'].map({'male': 0, 'female': 1})

X = data[['Pclass', 'Sex', 'Age']]
y = data['Survived']
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
```



Лабораторийн дасгал

Titanic Dataset-ийг ашиглан модоор ашиглах

```
# Загвар сургах
tree = DecisionTreeClassifier(max_depth=3)
tree.fit(X_train, y_train)

# Урьдчилсан таамаглал гаргах
y_pred = tree.predict(X_test)

# Үр дүнг үнэлэх
print(classification_report(y_test, y_pred))
```

- Загварын гүн (depth) болон бусад параметрийг өөрчилж, гүйцэтгэлийг сайжруул.
- Feature importance (шинж чанарын ач холбогдол)-ыг графаар харуул.



Лабораторийн дасгал

- Өгөгдлийн багануудаас холбогдол багатай, давхцаж буй онцлог шинжүүдийг арилгах.
- PCA (Principal Component Analysis) ашиглан онцлог шинжүүдийн хэмжээг багасгах.
- Онцлог шинжүүдийг бүрдүүлэх стратегийг сонгох: standardization, normalization, эсвэл log-transformation.
- Хэмжээг багасгасан онцлог шинжүүдтэй шинэ загварын гүйцэтгэлийг харьцуулж, хэрхэн сайжирснийг дүгнэх.

```
from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler
# Стандарчилсан өгөгдлийг хувиргах
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
# PCA ашиглан хэмжээ багасгах
pca = PCA(n_components=3)
X_pca = pca.fit_transform(X_scaled)
```



Лабораторийн дасгал

- Grid Search эсвэл Random Search ашиглан хамгийн сайн гиперпараметрүүдийг олох.
- Cross-validation ашиглан гиперпараметрүүдийн тогтвортой байдлыг шалгах.
- Оновчтой параметрүүдтэй загварын гүйцэтгэлийг хариуцсан үзүүлэлтүүдээр (F1, Accuracy, ROC-AUC) үнэлэх.
- **Grid Search-ийн үр дүнг харьцуулж, хамгийн тохиромжтой параметрүүдийг тодорхойлох.**

```
from sklearn.model_selection import GridSearchCV
from sklearn.ensemble import RandomForestClassifier
param_grid = {'n_estimators': [100, 150, 200], 'max_depth': [10, 20, None]}
grid_search = GridSearchCV(RandomForestClassifier(), param_grid, cv=5, scoring='accuracy')
grid_search.fit(X_train, y_train)
print("Best parameters:", grid_search.best_params_)
```



Лабораторийн дасгал

- Confusion Matrix болон classification report ашиглан загварын гүйцэтгэлийг үнэлэх.
- Ensemble аргууд: Random Forest, XGBoost ашиглан үр дүнг сайжруулах.
- **Загварын алдааны төрлийг тодорхойлж, хэт сургалт (overfitting) болон дутуу сургалт (underfitting) асуудлыг шийдвэрлэх.**

```
from sklearn.metrics import classification_report, confusion_matrix
y_pred = grid_search.best_estimator_.predict(X_test)
print(confusion_matrix(y_test, y_pred))
print(classification_report(y_test, y_pred))
# Random Forest болон XGBoost-ийн гүйцэтгэлийг харьцуулах
from xgboost import XGBClassifier
xgb_model = XGBClassifier()
xgb_model.fit(X_train, y_train)
y_pred_xgb = xgb_model.predict(X_test)
print(classification_report(y_test, y_pred_xgb))
```



Лабораторийн дасгал

- Confusion Matrix болон classification report ашиглан загварын гүйцэтгэлийг үнэлэх.
- Ensemble аргууд: Random Forest, XGBoost ашиглан үр дүнг сайжруулах.
- Загварын алдааны төрлийг тодорхойлж, хэт сургалт (overfitting) болон дутуу сургалт (underfitting) асуудлыг шийдвэрлэх.
- **Ensemble аргуудыг ашиглан загварын гүйцэтгэлийг сайжруулах болон ямар аргууд хамгийн өндөр гүйцэтгэлтэй болохыг тодорхойлох.**

```
from sklearn.metrics import classification_report, confusion_matrix
y_pred = grid_search.best_estimator_.predict(X_test)
print(confusion_matrix(y_test, y_pred))
print(classification_report(y_test, y_pred))
# Random Forest болон XGBoost-ийн гүйцэтгэлийг харьцуулах
from xgboost import XGBClassifier
xgb_model = XGBClassifier()
xgb_model.fit(X_train, y_train)
y_pred_xgb = xgb_model.predict(X_test)
print(classification_report(y_test, y_pred_xgb))
```

